

Modèles de Linguistique Computationnelle CM 2 : Bash, un langage utilitaire

M1 Langue et Informatique

Crédits: Gaël Lejeune, Karën Fort, lana Atanassova, Djame Seddah, Eleni Kogkitsidou, Olga Seminck

Alice Millour prenom.nom@sorbonne-universite.fr Yoann Dupont prenom.nom@sorbonne-universite.fr 2020-2021

Sorbonne-Université

Plan

 Bash

Expressions régulières

Pourquoi utiliser bash?

Bash = un langage intégré à linux qui permet (entre autres) :

- de naviguer dans le système de fichiers
- de visualiser / modifier les fichiers

 \Rightarrow utile pour manipuler les fichiers / ressources linguistiques utilisées en modélisation linguistique

Commande bash

\$ commande -option1 -option2 -option3 argument1 argument2

ligne de commande vs. script

deux modes d'utilisation :

- ligne de commande (directement dans le terminal):
 alice@helice:-/Documents/Work/Cours/misol030/2020-2021/coursi\$ echo "Hello world!"
 Hello world!
- script (dans un fichier qui est ensuite exécuté dans le terminal :

```
script.sh (~/Documents/Work/Cours/m1sol030/2020-2021/cours1) - gedit

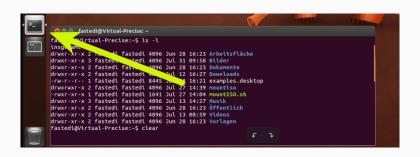
Ouvrir 

#!/bin/sh

cho "mon premier script"

alice@helice:~/Documents/Work/Cours/m1sol030/2020-2021/cours1$ chmod +x script.sh
alice@helice:~/Documents/Work/Cours/m1sol030/2020-2021/cours1$ ./script.sh
mon premier script
```

Le terminal



Le terminal interprète les commandes Bash

Le terminal - la base

se déplacer dans l'arborescence des fichiers avec la commande cd

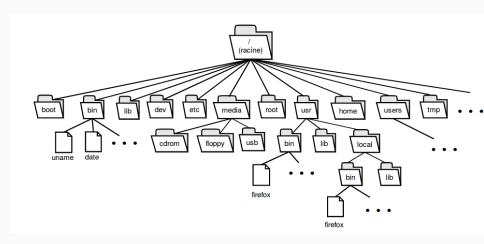


Figure 1 - arborescence des fichiers dans linux

Le terminal - la base

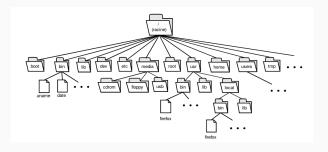


Figure 2 – arborescence des fichiers dans linux

- en utilisant les chemins absolus (par exemple /usr/local/bin)
- 2. en utilisant les chemins relatifs (rappel : . . désigne le dossier parent du dossier courant)

ex : comment se rendre dans le dossier lib depuis le dossier usb?

Le terminal - la base

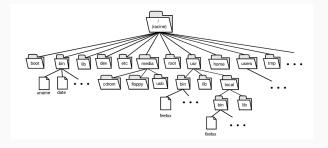


Figure 3 – arborescence des fichiers dans linux

- 1. \$ cd : déplace vers le dossier "home" de l'utilisateur courant
- 2. \$ cd : déplace vers la position précédente

```
alice@helice:~$ cd Documents/Work
alice@helice:~/Documents/Work$ cd
alice@helice:~$ cd -
/home/alice/Documents/Work
alice@helice:~/Documents/Work$
```

Exemple concret d'utilisation avancée (1)

```
NPP
Gras
        Gras
                        NPP
                                 g=m|n=s|s=p
                                                 ponct
                                                 ponct
                                                 q=fin=sis=c
Histoire
                                 q=fin=sis=def
                                 g=f|n=s|s=c
Indochine
                                                 ponct
        Plon
                                                 mod
                        PONCT
       Parts
                        NPP
                        PONCT
1979
        1979
Jules
        Jules
                        NPP
                        NPP
                                 g=min=sis=p
                       PONCT
                                 q=f|n=s|s=def
bataille
                                                 dep
Dien
        Dien
Bien
        Bien
        Phu
                PONCT
Julliard
        1963
                         NC
                                 s=card
                                                 mod
                        PONCT
        Albin
        Michel
                        NPP
                               s=w|sentid=frwiki 50.1000 00984 2
```

extraction des adverbes d'un corpus au format Conll :

```
$ cat corpus_francais.conll | grep ADV | cut -d' ' -f3 | sort | uniq
tr '_' ' ' > liste_adverbes.txt
```

Exemple concret d'utilisation avancée (2)

```
NPP
Gras
        Gras
                         NPP
                                 g=m|n=s|s=p
                                                  ponct
                                                  ponct
                                                  q=fin=sis=c
Histoire
                                 q=f|n=s|s=def
                                 g=f|n=s|s=c
                                                           obj.p
Indochine
                                                  ponct
        Plon
                                                  mod
        Parts
                         NPP
                         PONCT
1979
        1979
Jules
        Jules
                         NPP
                         NPP
                                 g=min=sis=p
                         PONCT
                         DET
                                 q=f|n=s|s=def
bataille
                                                  dep
Dien
Bien
        Bien
                                 s=p
        Phu
Julliard
1963
        1963
                                 s=card
                         PONCT
        Albin
        Michel
                         NPP
1989
                                 s=w|sentid=frwiki 50.1000 00984 :
```

Décompte de chaque catégorie grammaticale à partir du corpus :

```
$ cat corpus_francais.conll | cut -d' ' -f4 | sort | uniq -c
```

Plan

 Bash

Expressions régulières

Expressions régulières

expression régulière (regex) = chaîne de caractères, qui décrit, selon une syntaxe précise, un **ensemble de chaînes de caractères possibles**

Les regex permettent notamment de sélectionner des motifs :

- les adresses e-mail : $[a-zA-Z-]+@[a-zA-Z-]+[a-zA-Z]\{2,6\}$ \$
- les mots commençant par une majuscule : [A-Z] [a-z]+
- les mots d'au moins 5 lettres : [a-zA-Z]6
- etc.

https://fr.wikipedia.org/wiki/Expression_r%C3%A9guli%C3%A8re

Expressions régulières

Les expressions régulières répondent à une certaine syntaxe qu'il faut apprendre...

```
Tutoriel de prise en main : https://www.lucaswillems.com/fr/articles/25/tutoriel-pour-maitriser-les-expressions-regulieres
```

La semaine prochaine

Manipulation de bash avec les expressions régulières :

- manipuler les fichiers dont le nom correspond à un motif, par exemple tous les fichiers '.txt'
- extraire tous les mots *contenant un motif*, par exemple dé<u>manger</u>, <u>manger</u>ai, démangerait etc.
- extraire toutes les phrases contenant plus de n mots
- etc.