

# Modèles de Linguistique Computationnelle

CM 5 : formatage / compréhension de listes / expressions régulières et groupes

M1 Langue et Informatique

Crédits: Gaël Lejeune, Karën Fort, lana Atanassova, Djame Seddah, Eleni Kogkitsidou, Olga Seminck

Alice Millour prenom.nom@sorbonne-universite.fr Yoann Dupont prenom.nom@sorbonne-universite.fr 2020-2021

Sorbonne-Université

#### Organisation

#### Séance d'aujourd'hui

- (une) correction du TD3
- CM 5 :formatage des chaînes de caractères / compréhension de listes / expressions régulières et groupes
- TD 4 : Implémentation d'un agent conversationnel

#### Plan

Formatage

Compréhensions de listes

Expressions régulières et groupes

la syntaxe { }.format(value) ... pourquoi?

- lisibilité
- économie de code
- flexibilité

On peut utiliser plusieurs formats pour le paramètre à afficher :

- s strings
- d decimal integers (base-10)
- f floating point display
- c character
- b binary
- o octal
- x hexadecimal with lowercase letters after 9
- X hexadecimal with uppercase letters after 9
- e exponent notation

Cette syntaxe permet de passer des *paramètres* formatés à une chaîne de caractères

```
: # Formattage
 valeur s = "mot"
 print("{}".format(valeur s))
 valeur d = 3
 print("{}".format(valeur d))
 valeur f = 3.5
 print("{}".format(valeur f))
 valeur c = 37
 # conversion au format caractère
 print("{:c}".format(valeur c))
 print("{} est le code ASCIT en base 10 du caractère {:c}".format(valeur c, valeur c))
```

```
mot
3
3.5
%
arest le code ASCII en base 10 du caractère %
```

S'il n'y a pas d'ambiguïté, on n'est pas obligé de spécifier les formats :

```
# Mélanger les formats
name = input("nom : ")
date = input("aujourd'hui, nous sommes le : ")
duree_du_cours = input("la durée du cours est de (en heures) : ")
print('Le {} octobre, {} aura passé {}h dans la salle 219.'.format(date,name, duree_du_cours))
nom : Alice
aujourd'hui, nous sommes le : 14
la durée du cours est de (en heures) : 2,5
Le 14 octobre, Alice aura passé 2,5h dans la salle 219.
```

Le formatage permet d'améliorer la lisibilité des expressions :

```
# comment écrire : lundi précède mardi, mercredi, jeudi et vendredi ?
print(lundi + " précède " + mardi + ", " + mercredi + ", " + jeudi + " et " + vendredi + ".")
print('{} précède {}, {}, {} et {}.'.format(lundi, mardi, mercredi, jeudi, vendredi))
lundi précède mardi, mercredi, jeudi et vendredi.
lundi précède mardi, mercredi, jeudi et vendredi.
```

### Stocker les paramètres dans une liste

Le formatage permet d'améliorer la compacité des expressions :

La liste de valeurs est parcourue grâce à l'opérateur \*

```
[jours = "Lundi mardi mercredi jeudi vendredi samedi dimanche"
liste_jours = jours.split()
print(liste_jours)

print('{} précède {}, {}, {} et {}.'.format(*liste_jours))
['Lundi'. 'mardi'. 'mercredi'. 'jeudi'. 'vendredi'. 'samedi'. 'dimanche']
```

['Lundi', 'mardi', 'mercredi', 'jeudi', 'vendredi', 'samedi', 'dimanche'] Lundi précède mardi, mercredi, jeudi et vendredi.

#### Plan

Formatage

Compréhensions de listes

Expressions régulières et groupes

#### Compréhension de liste

```
new_list = [function(item) for item in list if condition(item)]
```

Les codes 1 et 2 sont équivalents

#### Plan

Formatage

Compréhensions de listes

Expressions régulières et groupes

#### Expressions régulières et groupes

Les groupes sont des portions d'expressions régulières délimitées par des

#### parenthèses

```
# les parenthèses permettent de définir des groupes
jours = "Lundi mardi mercredi jeudi vendredi samedi dimanche"
prefixe_di = [re.search(r'(\w+)di\b', jour) for jour in jours.split()]
print([prefixe_di[i].group(1) for i in range(len(prefixe_di)) if prefixe_di[i] != None])
['Lun', 'mar', 'mercre', 'jeu', 'vendre', 'same']
```

### Expressions régulières et groupes

Voir code\_cours.ipynb